

R入門

基礎生物学研究所
情報管理解析室
内山 郁夫

1

Rとは

- ベル研究所で開発された統計処理言語「S」を基に、フリーソフトとして開発された統計解析環境・プログラミング言語
- コマンドラインインターフェイスが基本。対話的なコマンド実行による解析のほか、スクリプトを書いて一括処理を行うことも可能
- ベクトル・行列演算が簡便かつ効率的に行える
- 独自の関数を作成することによって機能拡張が可能
- 作成した関数等をパッケージ単位でまとめることにより、機能拡張が容易に行える。様々なパッケージを導入することにより、最先端の統計手法を用いることができる。

2

作業ディレクトリの設定

- 作業ディレクトリ: 読み込むデータファイルや結果を書き出すファイルを保存するディレクトリ。
- メニューから、その他→作業ディレクトリの変更をえらんでディレクトリを選択する。

作業ディレクトリ data/IU に移動

- 作業ディレクトリを常に固定したい場合は、環境設定から起動タブを開いて初期ディレクトリを設定する。
- 作業ディレクトリをコマンドで設定することも可能
 `setwd("ディレクトリ名")` 作業ディレクトリの設定
 `getwd()` 作業ディレクトリの確認

3

スカラー演算

```
> 1+3
```

```
[1] 4
```

```
> 1+3*5
```

```
[1] 16
```

```
> a <- 1+3*5
```

```
> a
```

```
[1] 16
```

```
> a > 10
```

```
[1] TRUE
```

通常通り、*(かけ算)は
+(足し算)より優先する

結果を変数 a に代入する

a とだけタイプすると、変
数aの内容が出力される

論理演算は、論理値TRUE
またはFALSEを返す

4

変数と代入

- 計算結果を変数に代入することにより、結果を再利用できる
 - 変数名にはアルファベット、数字、'.' (dot)、'_' (underscore)が利用できる。ただし、先頭はアルファベットまたはドット。
 - 大文字と小文字は区別される。
- 代入を表す演算子には、`<-` `=` `->` の3通りがある。以下の3つはいずれも `a` に `4` が代入される。

```
> a <- 1 + 3
> a = 1 + 3
> 1 + 3 -> a
```

5

ヒストリー(履歴)

- コンソール上で、上下の矢印キー(↑↓)によって、コマンドの履歴を前後にたどることができる。
- 左右の矢印キー(←→)によって、カーソルを左右に動かせる。これによってコマンドの編集ができる。
- 以下のコントロールキーを使った操作も可能
 - Control+P 履歴を前に移動(↑と同じ)
 - Control+N 履歴を後ろに移動(↓と同じ)
 - Control+B カーソルを左に移動(←と同じ)
 - Control+F カーソルを右に移動(→と同じ)
 - Control+A カーソルを行の先頭に移動
 - Control+E カーソルを行の最後に移動
- GUIからヒストリーパネルを使って履歴をたどることも可能



ヒストリーパネルの表示・非表示

6

ベクトル

```
> a <- c(1, 3, 7, 4, 6)  ベクトルは関数 c を用いて
> a                      作成する
[1] 1 3 7 4 6
> b <- 3:7                3から7までの連続した整数
> b
[1] 3 4 5 6 7
> length(a)              ベクトルaの長さ(要素数)
[1] 5
> b[3]                   bの3番目の要素
[1] 5
```

7

ベクトル演算

a=c(1,3,7,4 6); b=c(3,4,5,6,7) と設定されている

```
> 1 + a                  aの各要素に1を加える
[1] 2 4 8 5 7
> 2 * a                  aの各要素を2倍する
[1] 2 6 14 8 12
> a + b                  aとbの要素ごとの和をとる
[1] 4 7 12 10 13
> a * b                  aとbの要素ごとの積をとる
[1] 3 12 35 24 42
> a > 3                  aの要素ごとに3より大きいか比較する
[1] FALSE FALSE TRUE TRUE TRUE
> a < b                  aとbを要素ごとに大小を比較する
[1] TRUE TRUE FALSE TRUE TRUE
```

8

基本統計量の計算

`a=c(1,3,7,4,6)`と設定されている

<code>> length(a)</code>	aの長さ(要素数)
<code>> sum(a)</code>	aの要素の合計値
<code>> mean(a)</code>	aの要素の平均値
<code>> median(a)</code>	aの要素の中央値
<code>> var(a)</code>	aの要素の不偏分散
<code>> sd(a)</code>	aの要素の標準偏差

問題) `mean(a)`を`sum(a)`と`length(a)`を使って計算してみよう。

9

ベクトル要素の抽出

`a=c(1,3,7,4,6)`と設定されている

<code>> a[2:4]</code>	# 2番目から4番目までの要素
[1] 3 7 4	
<code>> a[c(3,5,2)]</code>	# 3, 5, 2番目の要素
[1] 7 6 3	
<code>> a[c(T,T,F,F,T)]</code>	# Tである要素だけ出力
[1] 1 3 6	
<code>> a[a > 3]</code>	# <code>a>3</code> がTRUEである要素だけ出力
[1] 7 4 6	

10




並べかえ(ソート)と順序づけ(ランク)

```
> x <- c(3,5,8,6,2,4,9)
> sort(x)           # 小さい順に並べかえ
[1] 2 3 4 5 6 8 9
> sort(x, decreasing=TRUE) # 大きい順
[1] 9 8 6 5 4 3 2
> rank(x)           # 小さい順に順序づけ
[1] 2 4 6 5 1 3 7
```

11

プロットの作成(1)


```
> x
[1] 3 5 8 6 2 4 9
> plot(x)
> plot(x,type="l")
> barplot(x)
```



12

プロットの作成(2)

```
# x <- c(3,5,8,6,2,4,9)と設定されている
> y <- c(4,6,9,3,6,8,2)
> par(mfrow=c(1,2)) # 2つのプロットを表示
# x,y をx軸、y軸にとって散布図としてプロット
> plot(x,y)
# x,yを別々にプロット。まずxをプロット。点と線を両方描く。
> plot(x,type="b")
# yを重ねてプロット。linesは枠を描き直さずに線だけを引く。
# lty はline type, col は colorを指定。
> lines(y, type="b", lty=2, col=2)
```



13

Rにおける基本データ型

- Rの「原子データ型」として以下のものがある
 - 数値型 numeric(実数または整数)
 - 論理型 logical(TRUE/FALSE)
 - 文字列型 character("abc", "123" のように、二重引用符で囲まれた文字列として表す)
- Rの原子データはベクトルである。スカラー値も長さ1のベクトルである。
- 異なる型のデータを集めた構造として「リスト」がある。
- mode(x) によって、変数 x の型を調べられる

14

演算子

- 算術演算子
+ (加算) - (減算) * (乗算) / (除算),
%% (整数除算) %% (剰余) ^ (累乗)
例) 5 / 2 (=2.5) 5 % / % 2 (=2) 5 %% 2 (=1)
- 論理演算子
& (論理積「かつ」) | (論理和「または」) ! a (aの否定)
- 比較演算子
>, >=, <, <= (不等号) == (等しい) != (等しくない)

これらの演算子はベクトルの要素ごとにはたらく

(例) a=c(1,3,7,4,6)と設定されている

```
> a >= 2 & a < 5  
[1] FALSE TRUE FALSE TRUE FALSE
```

15

ワークスペースとオブジェクト

- コンソール上で ls() または objects() とすると、変数に保存されたデータ(オブジェクト)のリストを参照できる。

```
> ls()  
[1] "a" "b" "x"
```

- ワークスペースブラウザ(メニューバー「ワークスペース」から起動)でより詳細な情報を閲覧可能
- rm(変数名) で、オブジェクトを消去できる。

16

関数

関数名(引数1, 引数2, ...)

- 関数は、一般に複数の引数を入力としてとり、何らかの計算を行って一つのオブジェクトを返す(戻り値)。
- 引数には、必須のものと省略可能なものがある。後者は省略すると「デフォルト値」が使用される。
- 引数は、順番によって指定する方法と、「名前=値」の形式で指定する方法がある。通例、必須の引数は前者、選択可能な引数は後者で指定する。

例1) ベクトル x を小さい順(increasing order)でソートする

```
sort(x)
```

例2) ベクトル x を大きい順 (decreasing order)でソートする

```
sort(x, decreasing=TRUE)
```

17

マニュアルの表示

- help(関数名)でマニュアルを表示する

```
> help(median)
```

```
median      package:stats      R Documentation
Median Value
Description:
  Compute the sample median.
Usage:
  median(x, na.rm = FALSE)
Arguments:
  x: an object for which a method has been defined, or a numeric
    vector containing the values whose median is to be computed.
  na.rm: a logical value indicating whether 'NA' values should be
    stripped before the computation proceeds.
Details:
  This is a generic function for which methods can be written.
  However, the default method makes use of 'sort' and 'mean' from
  package 'base', both of which are generic, and so the default
  method will work for most classes (e.g. "Date") for which a
  median is a reasonable concept.
Value:
  The default method returns a length-one object of the same type as
  'x', except when 'x' is integer of even length, when the result
  will be double.
  If there are no values or if 'na.rm = FALSE' and there are 'NA'
  values the result is 'NA' of the same type as 'x' (or more
  generally the result of 'x[FALSE][NA]').
References:
  Becker, R. A., Chambers, J. M. and Wilks, A. R. (1988) _The New S
  Language_. Wadsworth & Brooks/Cole.
See Also:
  'quantile' for general quantiles.
Examples:
  median(1:4)# = 2.5 [even number]
  median(c(1:3,100,1000))# = 3 [odd, robust]
```

Description: 関数の簡単な説明

Usage: 関数の呼び出し方

median(x, na.rm = FALSE)

x: 必須の引数

na.rm: 省略可能な引数

デフォルト値はFALSE

Arguments: 各引数の詳しい説明

Details: 関数の動作の詳しい説明

Values: 戻り値の説明

Reference: 方法に関する文献

See Also: 関連するコマンド

Examples: 実行例

18

plotのオプション

- `main="title"` グラフのタイトル
 - `xlab(ylab)="label"` x軸(y軸)のラベル
 - `log="xy"` 対数軸の指定
 - `xlim(ylim)=c(0,100)` x軸(y軸)の値の範囲の設定
 - `type="l" "p"(点), "l"(線), "b"(両方), "n"(枠だけ) など`
 - `lty=1` プロットする線の種類
 - `pch=1` プロットする点の種類(文字)
 - `col=2` プロットする点および線の色
 - `cex=0.8` プロットする文字の大きさ
- ベクトルとして指定することにより、点ごとに色や種類を変更することもできる。例) `pch=c(1,2,1,3,2)`

	.	▲	+	×	◇	▽	⊠	✱	⬠	⊕
pch	1	2	3	4	5	6	7	8	9	10
col	1	2	3	4	5	6	7	8	9	10
cex	0.25	0.5	0.75	1	1.25	1.5	1.75	2	2.25	2.5

- ✧ plotのオプションは、`help(plot)`だけでは調べられない。一部のオプションは `help(plot.default)`, `plot(par)`を参照する必要がある。
- ✧ 既存のグラフ上に線を重ねる場合は`lines`, 点を重ねる場合は`points`を使う。
- ✧ 凡例をつけたいときは`legend`関数を使う。

19

行列の作成

一つのベクトルを行列の形に並べる

```
> v <- 1:9
```

9つの要素を持つベクトル

```
> m1 <- matrix(v, 3, 3)
```

これを3行3列の行列として定義

```
> m1
```

```
      [,1] [,2] [,3]
[1,]    1    4    7
[2,]    2    5    8
[3,]    3    6    9
```

複数のベクトルを行または列として束ねる

```
> a <- c(1,3,5)
```

```
> b <- c(2,4,9)
```

```
> c <- c(3,5,7)
```

3つの要素を持つベクトル3つ

```
> m2 <- cbind(a,b,c)
```

これらを列(縦)に並べて行列とする

```
> m2
```

```
      a b c
[1,] 1 2 3
[2,] 3 4 5
[3,] 5 9 7
```

20

行列の要素の取り出し

```
> m1
      [,1] [,2] [,3]
[1,]    1    4    7
[2,]    2    5    8
[3,]    3    6    9
> m1[2,3]
[1] 8
> m1[2,]
[1] 2 5 8
> m1[,3]
[1] 7 8 9
> m1[1:2,2:3]
      [,1] [,2]
[1,]    4    7
[2,]    5    8
> dim(m1)
[1] 3 3
```

2行3列目の要素

2行目の要素すべてをベクトルとして取り出す

3列目の要素すべてをベクトルとして取り出す

1,2行目と2,3列目の要素からなる
部分行列を取り出す

行列の大きさ

21

行列の演算

```
> m1+m2
      a  b  c
[1,]  2  6 10
[2,]  5  9 13
[3,]  8 15 16
> m1*m2
      a  b  c
[1,]  1  8 21
[2,]  6 20 40
[3,] 15 54 63
> m1 %*% m2
      a  b  c
[1,] 48 81 72
[2,] 57 96 87
[3,] 66 111 102
> t(m1)
      [,1] [,2] [,3]
[1,]    1    2    3
[2,]    4    5    6
[3,]    7    8    9
```

要素ごとの足し算

要素ごとのかけ算

行列積

転置行列(行と列の入れ換え)

22

データフレーム

- Rの統計解析でもっとも基本的となるデータ。
- 行列のような表形式のデータだが、各列が一般に異なる型のデータを持ちうる(行列はすべてが同じ型のデータ)。
- 多くの場合、各行が個体を、各列が個体を持つ属性を表す。
- 通常、タブ区切りテキストやエクセルファイル等から読み込んで処理する。

lung_cancer.txt
肺がん患者の遺伝子発
現プロファイルデータ
(GEO: GDS3257)の抜粋

tissue: 腫瘍or正常
smoking: 喫煙歴
stage: 癌のステージ
gender: 性別
gene1 – gene6:
遺伝子発現データ

ID_REF	tissue	smoking	stage	gender	gene1	gene2	gene3
GSM254629	tumor	never	stage I	female	7.4191	5.9318	5.67496
GSM254648	tumor	never	stage I	female	7.5627	6.93398	5.76701
GSM254694	tumor	never	stage I	female	7.54599	7.53287	5.84134
GSM254701	tumor	never	stage I	female	8.31452	7.88291	5.44759
GSM254728	tumor	never	stage I	female	7.19835	6.58398	4.79089
GSM254726	tumor	never	stage I	male	11.9811	8.45595	5.7083
GSM254639	tumor	never	stage II	female	7.41762	7.75681	4.74084
GSM254652	tumor	never	stage II	female	7.62703	7.7446	4.69937
GSM254700	tumor	never	stage II	female	7.40064	10.1866	4.92612
GSM254625	tumor	never	stage II	male	11.9	8.89865	6.69416
GSM254636	tumor	never	stage III	female	7.09852	6.39122	4.54743
GSM254659	tumor	never	stage III	female	7.39159	7.06924	5.12113
GSM254680	tumor	never	stage III	female	7.32462	7.24284	4.90953
GSM254686	tumor	never	stage III	female	7.65883	7.93856	5.09535
GSM254718	tumor	never	stage III	female	7.67937	7.03277	5.64789
GSM254674	tumor	never	stage IV	male	11.0711	6.3368	5.48673
GSM254668	tumor	former	stage I	male	10.9011	6.52462	5.19564

データフレームの読み込み(1)

```
read.table(file, options... )
read.delim(file, options... )
```

タブ区切りテキストファイル lung_cancer.txt からデータの読み込み

```
> cancer <- read.delim("lung_cancer.txt")
```

> head(cancer) データの先頭数行のみの表示

```
  ID_REF tissue smoking stage gender gene1 gene2 ...
1 GSM254629 tumor  never stage I female  7.41910 5.93180 ...
2 GSM254648 tumor  never stage I female  7.56270 6.93398 ...
3 GSM254694 tumor  never stage I female  7.54599 7.53287 ...
4 GSM254701 tumor  never stage I female  8.31452 7.88291 ...
5 GSM254728 tumor  never stage I female  7.19835 6.58398 ...
6 GSM254726 tumor  never stage I   male 11.98110 8.45595 ...
```

> edit(cancer) エディタ上でのデータ表示

データフレームの読み込み(2)

	ヘッダなし	ヘッダ行あり	ヘッダ行、ヘッダ列あり																																																	
ファイルの形式	<table><tr><td>198</td><td>119</td></tr><tr><td>192</td><td>83</td></tr><tr><td>191</td><td>110</td></tr><tr><td>191</td><td>91</td></tr></table>	198	119	192	83	191	110	191	91	<table><tr><th>Height</th><th>Weight</th></tr><tr><td>198</td><td>119</td></tr><tr><td>192</td><td>83</td></tr><tr><td>191</td><td>110</td></tr><tr><td>191</td><td>91</td></tr></table>	Height	Weight	198	119	192	83	191	110	191	91	<table><tr><th>ID</th><th>Height</th><th>Weight</th></tr><tr><td>1</td><td>198</td><td>119</td></tr><tr><td>2</td><td>192</td><td>83</td></tr><tr><td>3</td><td>191</td><td>110</td></tr><tr><td>4</td><td>191</td><td>91</td></tr></table>	ID	Height	Weight	1	198	119	2	192	83	3	191	110	4	191	91	<table><tr><th></th><th>Height</th><th>Weight</th></tr><tr><td>1</td><td>198</td><td>119</td></tr><tr><td>2</td><td>192</td><td>83</td></tr><tr><td>3</td><td>191</td><td>110</td></tr><tr><td>4</td><td>191</td><td>91</td></tr></table>		Height	Weight	1	198	119	2	192	83	3	191	110	4	191	91
	198	119																																																		
	192	83																																																		
	191	110																																																		
	191	91																																																		
Height	Weight																																																			
198	119																																																			
192	83																																																			
191	110																																																			
191	91																																																			
ID	Height	Weight																																																		
1	198	119																																																		
2	192	83																																																		
3	191	110																																																		
4	191	91																																																		
	Height	Weight																																																		
1	198	119																																																		
2	192	83																																																		
3	191	110																																																		
4	191	91																																																		
read.table オプション	header=FALSE	header=TRUE	header=TRUE, row.names=1	(指定なし)																																																

read.table が読み込みのための基本的な関数だが、デフォルト値の異なる読み込み関数がいくつか用意されている

read.table(file)	デフォルトでセパレータは空白文字、header=FALSE
read.delim(file)	デフォルトでセパレータがタブ、header=TRUE
read.csv(file)	デフォルトでセパレータがコンマ、header=TRUE

25

データフレームの情報表示

str(data)	data のデータ構造の表示
summary(data)	data の内容サマリの表示

> **str(cancer)** 各列のデータ型と内容の一部を表示

```
'data.frame': 107 obs. of 11 variables:
 $ ID_REF : Factor w/ 107 levels "GSM254625","GSM254626",...: 5 24 70 77 104 102 15 28
 $ tissue : Factor w/ 2 levels "normal","tumor": 2 2 2 2 2 2 2 2 ...
 $ smoking: Factor w/ 3 levels "current ","former ",...: 3 3 3 3 3 3 3 3 ...
 $ stage : Factor w/ 4 levels "stage I","stage II",...: 1 1 1 1 1 1 2 2 2 2 ...
 $ gender : Factor w/ 2 levels "female","male": 1 1 1 1 1 2 1 1 1 2 ...
 $ gene1 : num 7.42 7.56 7.55 8.31 7.2 ...
 $ gene2 : num 5.93 6.93 7.53 7.88 6.58 ...
 .....
```

> **summary(cancer)** 各列のデータの分布の要約を表示

	ID_REF	tissue	smoking	stage	gender	gene1
GSM254625:	1	normal:49	current :40	stage I :45	female:38	Min. : 6.729
GSM254626:	1	tumor :58	former :36	stage II :35	male :69	1st Qu.: 7.543
GSM254627:	1		never :31	stage III:21		Median :11.224
GSM254628:	1			stage IV : 6		Mean :10.074
GSM254629:	1					3rd Qu.:11.875
GSM254630:	1					Max. :12.659
(Other)	:101					

26

因子 factor

- gender (male, female)のように、限られた数のカテゴリで表現されるもの。
- 因子の取り得る値を水準levelという。
例) genderは2つ、smokingは3つの水準を持つ
- 文字列として表示されるが、内部的には整数値で保持されている。

27

データフレームの要素の取り出し

```
> cancer[5,]                                5行目の人のデータの取り出し
  ID_REF tissue smoking stage gender gene1 gene2 gene3 gene4
5 GSM254728 tumor  never stage I female 7.19835 6.58398 4.79089 7.26575

> cancer[,6]                                6列目(gene1)の取り出し
 [1] 7.41910 7.56270 7.54599 8.31452 7.19835 11.98110 7.41762 7.62703
 [9] 7.40064 11.90000 7.09852 7.39159 7.32462 7.65883 7.67937 11.07110
[17] 10.90110 9.30280 11.42620 12.10840 11.00710 11.43570 9.58576 11.37820
[25] 11.46580 11.98080 7.17584 11.62510 11.22410 7.45557 7.70254 11.65150
[33] 11.01420 12.03040 7.00001 7.53943 10.81220 11.47220 12.05180 11.37000
....

> cancer$gene1                                gene1 データの取り出し
                                         (名前によるアクセス。cancer[,6]と同じ)

> cancer[7:10,2:7]                            7-10行、2-7列の要素からなる部分データの取り出し
  tissue smoking stage gender gene1 gene2
7 tumor  never stage II female 7.41762 7.75681
8 tumor  never stage II female 7.62703 7.74460
9 tumor  never stage II female 7.40064 10.18660
10 tumor never stage II male 11.90000 8.89865
```

28

データフレームの操作

条件式による部分データの抽出

`subset(データフレーム, 条件式)`

性別が女性でgene1の発現が8以上

```
> subset(cancer, gender=="female" & gene1 > 8)
```

```
  ID_REF tissue  smoking      stage gender  gene1  gene2  gene3  gene4
4  GSM254701  tumor   never    stage I female  8.31452  7.88291  5.44759  5.99769
56 GSM254687  tumor current stage III female 10.15150  7.64551  6.61338  7.24318
...
```

喫煙歴がある人

```
> subset(cancer, smoking %in% c('former','current'))
```

...

その数(行数をカウント)

```
> nrow(subset(cancer, smoking %in% c('former','current')))
```

```
[1] 76
```

A %in% B ベクトルAの各要素について、ベクトルBの要素のいずれかと一致すればTRUE, そうでなければFALSEを返す。

```
> c("A", "B", "C", "B", "A") %in% c("B", "C")
```

```
[1] FALSE  TRUE  TRUE  TRUE FALSE
```

29

データフレームのファイルへの書き出し

`write.table(data, file="", options...)`

サブセットの切り出し

```
> cancer.subset <- subset(cancer, gene1 > 8)
```

タブ区切りテキストとして画面に表示

```
> write.table(cancer.subset, sep="\t")
```

その形式でファイルに保存

```
> write.table(cancer.subset, sep="\t",
  file="cancer.subset.txt")
```

そのまま読み込んで表示してみる

```
> read.table("cancer.subset.txt")
```

30

Rによるデータ解析

plotによる散布図の作成

各カラム対総当たりの散布図を作成する

```
> plot(cancer)
```

pairs(cancer)としても同じ

gene3とgene4の散布図を作成する

```
> plot(cancer$gene3, cancer$gene4)
```



以下もほぼ同じプロットを生成する

```
> plot(gene4 ~ gene3, cancer)
```

tissue (cancer/normal) によって点の色づけする

```
> plot(gene4 ~ gene3, cancer,  
      col=tissue)
```

cancer\$tissue は normal=1, tumor=2 として定義されており、各点が 1=black, 2=red で色づけされる。



Rによるデータ解析

回帰直線の追加

gene3とgene4の散布図(前掲)

```
> plot(gene4 ~ gene3, cancer)
```

線型モデルを用いた直線への当てはめ(回帰直線の決定)

```
> lm(gene4 ~ gene3, cancer)
```


...(結果は画面に出力される)...

結果を変数 result.lm に代入

```
> result.lm <- lm(gene4 ~ gene3,  
                  cancer)
```

この結果を使って回帰直線をプロットに追加

```
> abline(result.lm)
```



モデル式と線型モデル

- `lm` の第1引数で指定される式は、データを当てはめるモデル式を簡潔に表現したものとなっている

例) X_1, X_2 が説明変数、 Y が目的変数として、

$$Y = a * X_1 + b * X_2 + c + \varepsilon \text{ (残差)}$$

という式に当てはめる(係数 a, b, c の最適な値を決める)ことを

$$Y \sim X_1 + X_2$$

と記述する。

- モデル式が係数の一次式で表されるモデルを線型モデルといい、最小二乗法で当てはめが行われる。`lm`関数では、係数の決定と同時に、係数が有意に0でないといえるかの検定も行われる。
- 線型モデルへの当てはめは、回帰分析だけでなく、カテゴリ変数を説明変数とした分散分析においても用いられる。

33

Rによるデータ解析 回帰分析結果の詳細表示

```
> par(mfrow=c(2,2)) # 4つのプロットを 2x2 の領域に同時に表示  
> plot(result.lm) # 解析結果からプロットの作成
```

プロットから誤差(残差)の分布が適切か(正規分布に従っているか)を確認

```
> summary(result.lm) # 解析結果の詳細表示
```

Call:

```
lm(formula = gene4 ~ gene3, data = cancer)
```

Residuals:

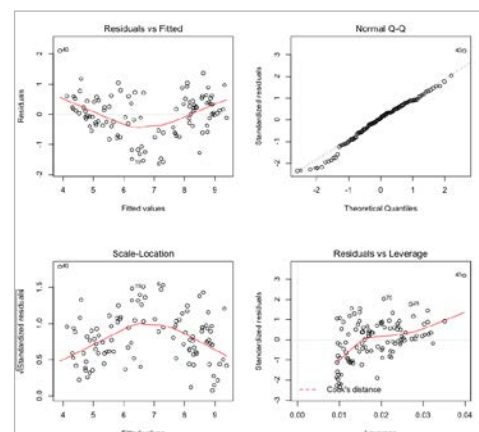
Min	1Q	Median	3Q	Max
-2.27983	-0.41889	-0.01643	0.45094	1.44834

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.86604	0.24801	7.524	1.9e-11 ***
gene3	0.87403	0.03514	24.870	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6395 on 105 degrees of freedom
Multiple R-squared: 0.8549, Adjusted R-squared: 0.8535
F-statistic: 618.5 on 1 and 105 DF, p-value: < 2.2e-16



係数が0でない値を持つといえるかを統計的に検定


解析が終わったらプロットウィンドウを閉じるか `par(mfrow=c(1,1))` して、プロットの設定を元に戻しておく

Rによるデータ解析

boxplotの作成

性別ごとのgene1の発現量をboxplotで比較する

```
> plot(gene1 ~ gender, cancer)
```



boxplot(gene1 ~ gender, cancer)
としてもほぼ同じ

35

Rによるデータ解析

t検定

2組の標本の平均値に差があるかどうかを検定する

男女でgene1の発現量に違いがあるかどうかをt検定で検定する

男性のgene1発現量

```
> gene1.m <- subset(cancer, gender=="male")$gene1
```

女性のgene1発現量

```
> gene1.f <- subset(cancer, gender=="female")$gene1
```

t検定の実行（等分散性を仮定しないWelchの検定）

```
> t.test(gene1.m, gene1.f)
```

別法（データフレームから直接データを取り出して検定を実行する）

```
> t.test(gene1 ~ gender, cancer)
```

36

Rによるデータ解析

分散分析

3組以上の標本間で平均値に差があるかどうかを検定する

癌のステージによってgene1の発現に違いがあるかどうかを分散分析で検定する

```
> aov(gene1 ~ stage, cancer)
Call:
aov(formula = gene1 ~ stage, data = cancer)

Terms:
              stage Residuals
Sum of Squares   47.0675   399.6562
Deg. of Freedom      3       103

Residual standard error: 1.969812
Estimated effects may be unbalanced

結果を変数 result.aov に格納してsummaryで出力
> result.aov <- aov(gene1 ~ stage, cancer)
> summary(result.aov)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
stage	3	47.1	15.69	4.043	0.00921 **
Residuals	103	399.7	3.88		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

この結果については練習問題3も参照のこと³⁷

解析結果の保存

```
# 指定したオブジェクトを "cancer.Robj" という
# ファイルに保存
> save(cancer, result.lm, result.aov,
       file="cancer.Robj")
```

```
# 保存したオブジェクトをファイルからロードする
> load("cancer.Robj")
```

```
# 現在のワークスペース中のオブジェクトをすべて
# デフォルトの保存ファイル(".RData")に保存。
> save.image()
```

- 明示的にsave.image()コマンドを実行しなくても、終了時にワークスペースを保存するか聞かれるので、そこで保存を選択することにより保存できる。
- ここで保存したデータは、現在の作業ディレクトリが起動時のディレクトリと同じであれば、次回起動時に自動的にロードされるが、ディレクトリを変更した場合はload(".RData")で明示的にロードする必要がある。

リスト

- ベクトルは同一の型のデータを要素とするが、リストは任意の一般に異なる型のデータを要素として含むことができる。

```
> list(1, "a")
```

- リストは、ベクトルや行列のほか、リストをも要素として含むことができるため、複雑なデータを表現できる。

```
> list(c(1,2), c("a","b"), list(1, "a"))
```

- リストの各要素は[[]]で参照できるほか、名前をつけて参照することもできる。

```
> x <- list(first=1, second="b")
```

```
> x[[1]]      # 1番目の要素
```

```
[1] 1
```

```
> x$second    # second という名前の要素
```

```
[1] "b"
```

- データフレームのほか、各種の統計処理の結果などもリストとして表現されている。

例) データフレームであるcancerをリストとして見る

```
> as.list(cancer)
```

39

オブジェクトの属性とクラス

- 統計解析の結果などは、一般に決まった型と名前の要素を持ち、一定のクラス名をアサインされたリスト(オブジェクト)として返される。

例) aov 関数の結果を格納した変数 result.aov

```
> class(result.aov)  # クラス名の表示
```

```
[1] "aov" "lm"
```

```
> names(result.aov)  # 要素名の一覧の表示
```

```
[1] "coefficients" "residuals" "effects"
```

```
... (以下略) ...
```

```
> str(result.aov)    # データ構造の階層的な表示
```

```
List of 13
```

```
$ coefficients : Named num [1:4] 10.334 0.195 -1.584 -0.224
```

```
..- attr(*, "names")= chr [1:4] "(Intercept)" "stagestage II" ..
```

```
... (以下略) ...
```

- このオブジェクトの詳細は、help(lm)のValueセクションで確認できる

40

総称関数 generic function

- plot, print, summaryなど多くの関数は、引数となるオブジェクトのクラスによって、異なる関数が呼び出されるようになっている。これらを総称関数という
 - 例) plot は、引数のクラスによって plot.data.frame, plot.formula, plot.lmなどが呼び出される。デフォルトでは、plot.default が呼び出される。
- これにより、Rでは典型的には以下のような定型的な処理の流れによって解析が進められる。

```
> result <- some.function(data, opt=value, ...)
> summary(result)      解析結果の要約の表示
> plot(result)         解析結果に基づくプロットの作成
```

参考) コンソールで単に x と入力したときは、print(x) が実行されている。
print は総称関数であり、x のクラスによって表示される内容は違っている。

41

関数の作成(1)

- function 関数によって、新たな関数を作成できる

function (引数リスト) { 関数本体 }

例) 引数の2乗を計算して返す関数を square として定義

```
> square <- function(x) {
  sq <- x^2
  return(sq)
}
```

引数: 呼び出し時に指定した値が x に
代入され、関数本体が実行される

```
> square(1:5)      引数 1:5 を与えて関数の呼び出し
[1] 1 4 9 16 25
```

42

関数の作成(2)

- 関数は、通常はファイル上に作成し、読み込んで使う。ファイル上に作成したRコマンドを読み込むにはsource("ファイル名")とする。

ファイル plotAll.R (plotAll: 指定した2つの部分データフレーム間での総当たりプロットを作成する関数)

```
plotAll <- function(x, y=x) {  
  par(mfrow=c(ncol(x), ncol(y)))  
  for (i in 1:ncol(x)) {  
    x.name=names(x)[i]  
    for (j in 1:ncol(y)) {  
      y.name=names(y)[j]  
      if (x.name == y.name) {  
        plot(x[,i], main=x.name)  
      } else {  
        plot(x[,i], y[,j],  
             xlab=x.name, ylab=y.name)  
      }  
    }  
  }  
}
```

繰り返し

for (変数 in ベクトル) { 式 }

「変数」に「ベクトル」の要素を順次代入して、「式」を繰り返し実行する。

条件分岐

if (条件式) { 式1 } else { 式2 }

「条件式」がTRUEなら、「式1」を実行し、FALSEなら「式2」を実行する。

プログラムの読み込みと実行

```
> source("plotAll.R")  
> plotAll(cancer[,2:5], cancer[,6:11])
```

43

パッケージの利用

- 様々なパッケージをインストール、ロードすることによりRの機能を拡張できる。
- バイオインフォマティクス関連では、Bioconductorプロジェクトによって、膨大な種類のパッケージが提供されている。



パッケージインストーラ パッケージのインストール/更新



パッケージマネージャ パッケージのロード



コマンドラインからの実行

パッケージのインストール
`install.packages(パッケージ名)`

パッケージの更新
`update.packages(パッケージ名)`

パッケージのロード
`library(パッケージ名)`

44

練習問題

cancer データを使って、以下の問題を考えよう。

1. 男性で喫煙歴がある人のデータを抜き出せ。何人いるか。それらの人のgene1の発現データを取り出し、その平均値を計算せよ。
2. gene1 とgene2の散布図を作成し、genderによって点を色分けせよ。また、回帰直線进行。この回帰直線の係数は有意であると言えるか。
3. a) gene1の発現を、genderとstageの2因子を使ったモデル式 ($\text{gene1} \sim \text{gender} + \text{stage}$)を用いて分散分析せよ。この場合、まずgenderの効果が評価され、次にgenderの効果を除いたstageの効果が評価される。このときのstageの効果は有意といえるか。
b) `plot(gender ~ stage, cancer)`によってプロット(mosaicplot)を作成せよ。これにより、データセット中のstageの水準ごとにgenderの比率を確認できる。これからstageだけを使ったときの結果とa)の結果の違いが説明できるか。
4. cancerデータから各患者のgene1からgene6の発現量を抜き出した部分データフレームを作成し、変数 expressionに代入せよ。それを用いて `matplot(expression)`を実行せよ。このグラフは各患者を横軸に配置し、各患者におけるgene1～gene6の発現量を縦軸に沿ってプロットしたものである。このグラフから何か読み取れるか。(こうした多変量のデータは、多変量解析によって、より明確に特徴を分析できるようになる)